

Derin Öğrenme Yöntemleri ile Beyin Kanaması Tespiti:CNN ve ResNet50

line 1: 1st İrem Yağmur YURTSEVER
line 2: *Faculty of Engineering,
Computer Engineering*
line 3: Duzce University
line 4: Duzce , Turkey
line 5: ygm1976@gmail.com

line 1: 2st Salih KARAKUŞ
line 2: *Faculty of Engineering,
Computer Engineering*
line 3: Duzce University
line 4: Duzce , Turkey
line 5: sskarakussalih77@gmail.com

line 1: 3st Berkan UZ
line 2: *Faculty of Engineering,
Computer Engineering*
line 3: Duzce University
line 4: Duzce , Turkey
line 5: berkan200261@ogr.duzce.edu.tr

line 1: 4st Miray AYKIN
line 2: *Faculty of Engineering,
Computer Engineering*
line 3: Duzce University
line 4: Duzce , Turkey
line 5: mrykn188@gmail.com

line 1: 5st Özlem GÜNTEKİN
line 2: *Faculty of Engineering,
Computer Engineering*
line 3: Duzce University
line 4: Duzce , Turkey
line 5: ozlemguntekin48@gmail.com

Özet—Bu çalışmada beyin bilgisayarlı tomografi (BT) görüntüleri kullanılarak intrakraniyal kanama (beyin kanaması) tespiti gerçekleştiren derin öğrenme tabanlı bir sistem geliştirilmiştir. Önerilen sistem görüntülerin ön işleme aşamalarından geçirilmesi, veri artırma teknikleri ile veri seti sayısının artırılması ve farklı model mimarilerinin eğitilmesi süreçlerini içerir. Çalışma kapsamında iki farklı model ele alınmıştır: Birincisi sıfırdan tasarlanmış özgün bir Evrişimsel Sinir Ağı (CNN) ikincisi ise transfer öğrenme yaklaşımı kullanılarak geliştirilen ResNet50 tabanlı derin öğrenme modelidir. Özgün CNN modeli doğrulama aşamasında yaklaşık %89 doğruluk elde ederken, ResNet50 tabanlı model %85 doğruluk elde etmiştir.

Bu çalışma yalnızca model performansını artırmayı değil aynı zamanda geliştirilen sistemin klinik karar destek süreçleriyle uyumlu bir şekilde çalışmasını amaçlamaktadır. Kullanıcı dostu arayüz ve birleşik karar yaklaşımı sayesinde sistem pratik kullanım için uygun hale getirilmiştir.

Anahtar Kelimeler—Derin Öğrenme, CNN, ResNet50, Beyin Kanaması, Medikal Görüntüleme, BT

I. GİRİŞ

Beyin kanaması (intrakraniyal hemoraji) erken teşhis edilmediği halde ölümcül sonuçlara yol açabilen kritik bir nörolojik durumdur. Özellikle travma, hipertansiyon ve beyin damarlarında oluşan sorunlar gibi çeşitli nedenlerle ortaya çıkabilen bu durum hızlı müdahale gerektirmektedir. Zamanında ve doğru teşhis hastaların yaşam şansını doğrudan etkileyen temel unsurlardan biridir. Günümüzde beyin kanamasının teşhisinde en yaygın kullanılan yöntemlerden biri bilgisayarlı tomografi (BT) görüntülemesidir. Ancak bu görüntülerin uzman radyologlar tarafından manuel olarak incelenmesi zaman alıcı olmakla

birlikte yoğun iş yükü altında hata yapma riskini de beraberinde getirmektedir. Bu durum otomatik, güvenilir ve hızlı karar destek sistemlerine olan ihtiyacı artırmaktadır. Son yıllarda yapay zeka ve özellikle derin öğrenme teknikleri, medikal görüntü analizi alanında önemli başarılar elde etmiştir. Evrişimsel sinir ağları (CNN) görüntülerden anlamlı özellikler çıkarabilme yetenekleri sayesinde hastalık tespiti gibi görevlerde yaygın olarak kullanılmaktadır. Bu çalışmada beyin BT görüntüleri üzerinden intrakraniyal kanama (Beyin kanaması) tespiti yapabilen derin öğrenme tabanlı bir sistem geliştirilmiştir. Bu sistem kapsamında görüntüler ön işleme ve veri artırma aşamalarından geçirilmiş, ardından hem özgün bir CNN modeli hem de transfer öğrenme temelli bir ResNet50 modeli eğitilmiştir

II. LİTERATÜR TARAMASI

Literatürde beyin kanaması tespiti üzerine yapılan çalışmalar incelendiğinde, farklı makine öğrenmesi ve derin öğrenme yöntemlerinin kullanıldığı görülmektedir. Örneğin, S. Princess ve R. Vignesh tarafından yapılan çalışmada kuantum makine öğrenmesi (QML) ve BiLSTM yöntemleri birlikte kullanılarak MRI ve CT görüntüleri üzerinden beyin kanaması tespiti gerçekleştirilmiş ve klasik yöntemlere kıyasla daha hızlı ve verimli sonuçlar elde edilmiştir [1].

Benzer şekilde, Jayaganesh ve arkadaşları tarafından gerçekleştirilen çalışmada CNN tabanlı VGG16 modeli kullanılarak MRI görüntüleri üzerinde kanama var/yok sınıflandırması yapılmış ve yüksek doğruluk oranlarına ulaşılmıştır [2].

Nagendra ve arkadaşlarının yaptığı derleme çalışmasında ise makine öğrenmesi ve derin öğrenme tabanlı yöntemler karşılaştırılmış ve bu yöntemlerin performansları kapsamlı bir şekilde analiz edilmiştir [3].

Ayrıca, Saha ve arkadaşları tarafından önerilen DNN-Reg ve CNN tabanlı yaklaşım, CT görüntüleri üzerinde görüntü hizalama (image registration) problemi için kullanılmış ve %84.7 doğruluk, %12.2 MSE ve %87 NCC değerleri elde edilmiştir [4].


Son olarak, Priyanka ve arkadaşları tarafından yapılan çalışmada, 3D BT görüntüleri kullanılarak beyin kanaması segmentasyonu için 3D U-Net, 3D ResU-Net ve 3D CNN tabanlı derin öğrenme modelleri incelenmiş; patch tabanlı eğitim ile yüksek çözünürlüklü veriler etkin şekilde işlenmiş ve yapılan deneyler sonucunda 3D U-Net modelinin %96,6 doğruluk oranı ile en iyi performansı gösterdiği rapor edilmiştir [5].

III. MATERYAL VE YÖNTEM

A. Veri Seti

Bu çalışmada kullanılan veri seti Kaggle platformunda yayımlanan “Head CT Hemorrhage” veri setidir [6]. Bu veri seti beyin bilgisayarlı tomografi (BT) görüntülerinden oluşmakta olup toplam 200 adet görüntü içermektedir. Veri seti dengeli bir yapıya sahiptir ve 100 adet normal (kanama içermeyen) ile 100 adet kanamalı görüntüden oluşmaktadır. Tüm görüntüler PNG formatında ve üç kanallı RGB yapısındadır.

Veri setinin sınırlı büyüklükte olması derin öğrenme modellerinin etkin bir şekilde eğitilmesini zorlaştırmaktadır. Bu nedenle modelin genelleme yeteneğini artırmak ve overfitting problemini azaltmak amacıyla veri artırma tekniklerinden yararlanılmıştır. Ayrıca veri setinde hasta bazlı ek bir meta veri bulunmadığından, grup bazlı bölme işlemi gerçekleştirilememiştir. Bu nedenle veri seti, sınıf dengesini koruyacak şekilde stratified yöntem kullanılarak bölünmüştür.



Resim 1. Ham veri seti dağılımı

B. Veri Ön İşleme

Ham görüntüler derin öğrenme modellerine uygun hale getirilebilmesi için çeşitli ön işleme adımlarından geçirilmiştir. İlk olarak tüm görüntüler sabit bir giriş boyutu elde etmek amacıyla 224×224 piksel boyutuna yeniden ölçeklendirilmiştir. Ardından görüntüler OpenCV kütüphanesi kullanılarak RGB formatına dönüştürülmüş ve piksel değerleri normalize edilerek [0,1] aralığına getirilmiştir. Bu normalizasyon işlemi modelin eğitim

sürecinde sayısal stabilite sağlamasına ve daha hızlı öğrenmesine katkıda bulunmaktadır.

C. Veri Arttırma

Veri setinin küçük olması nedeniyle modelin ezberleme (overfitting) yapmasını engellemek amacıyla veri artırma teknikleri uygulanmıştır. Bu kapsamda TensorFlow Keras kütüphanesinde bulunan ImageDataGenerator sınıfı kullanılmıştır.

Veri artırma sürecinde görüntüler üzerinde rastgele dönüşümler uygulanmıştır. Bu dönüşümler arasında döndürme (rotation), yatay ve dikey kaydırma (shift), yakınlaştırma (zoom), eğme (shear) ve yatay çevirme (horizontal flip) işlemleri yer almaktadır. Bu sayede her bir görüntüden farklı varyasyonlar üretilmiş ve veri çeşitliliği artırılmıştır.

Uygulanan veri artırma işlemleri sonucunda veri seti yaklaşık 2600 görüntüye çıkarılmıştır. Böylece modelin farklı açılardan ve varyasyonlardan gelen görüntülere karşı daha dayanıklı hale gelmesi sağlanmıştır.

Önemli bir nokta olarak, veri sızıntısını (data leakage) önlemek amacıyla veri artırma işlemleri yalnızca eğitim veri seti üzerinde uygulanmış, doğrulama ve test veri setleri orijinal halleriyle bırakılmıştır.

D. Veri Bölme Ve Çapraz Doğrulama


Veri seti, modelin eğitim ve değerlendirme süreçlerinin sağlıklı bir şekilde yürütülebilmesi amacıyla eğitim (%70), doğrulama (%15) ve test (%15) olmak üzere üç ayrı bölüme ayrılmıştır. Bu bölme işlemi sırasında sınıf dağılımının korunması için stratified sampling yöntemi kullanılmıştır.

Test veri seti, modelin gerçek performansını ölçmek amacıyla eğitim sürecinden tamamen bağımsız tutulmuş ve hiçbir şekilde veri artırma işlemine tabi tutulmamıştır. Bu sayede modelin daha gerçekçi bir değerlendirmesi yapılabilmiştir.

Bunun yanı sıra model performansının daha güvenilir bir şekilde ölçülmesi amacıyla 5 katlı çapraz doğrulama (K-Fold Cross Validation) yöntemi uygulanmıştır. Bu yöntemde veri seti beş farklı alt kümeye ayrılmış ve her bir iterasyonda farklı bir küme doğrulama verisi olarak kullanılmıştır.

Bu yaklaşım sayesinde model, veri setinin farklı bölümleri üzerinde test edilerek daha genellenebilir bir yapı kazanmış ve elde edilen performans sonuçlarının güvenilirliği artırılmıştır.

E. Akış Şeması



Resim 2. Proje akış şeması

IV. MODEL MİMARİLERİ

A. Özgün CNN Modeli

Bu çalışmada önerilen ilk model, sıfırdan tasarlanmış bir evrişimsel sinir ağı (Convolutional Neural Network - CNN) mimarisidir. Model, görüntülerden otomatik olarak anlamlı özellikler çıkarabilen çok katmanlı bir yapıdan oluşmaktadır.

Modelin giriş katmanına $224 \times 224 \times 3$ boyutunda görüntüler verilmiştir. İlk aşamada, farklı filtreler kullanılarak görüntü üzerinde kenar, doku ve şekil gibi temel özellikler çıkarılmaktadır. Bu amaçla modelde üç adet evrişim (Conv2D) katmanı kullanılmıştır. İlk katmanda 32, ikinci katmanda 64 ve üçüncü katmanda 128 filtre yer almakta olup, her katmanda ReLU aktivasyon fonksiyonu tercih edilmiştir.

Her evrişim katmanının ardından kullanılan maksimum havuzlama (MaxPooling) katmanları sayesinde özellik haritalarının boyutu küçültülmüş ve önemli özellikler korunarak hesaplama maliyeti azaltılmıştır. Bu yapı, modelin daha verimli çalışmasını sağlamaktadır.

Evrişim ve havuzlama katmanlarından elde edilen özellikler, Flatten katmanı ile tek boyutlu vektöre dönüştürülmüş ve ardından tam bağlantılı (Dense) katmanlara aktarılmıştır. Bu aşamada kullanılan Dense katman, çıkarılan özellikleri birleştirerek sınıflandırma kararının verilmesini sağlamaktadır.

Modelde aşırı öğrenmeyi (overfitting) önlemek amacıyla %50 oranında Dropout katmanı kullanılmıştır. Dropout mekanizması, eğitim sırasında rastgele nöronları devre dışı bırakarak modelin genelleme yeteneğini artırmaktadır.

Son katmanda sigmoid aktivasyon fonksiyonu kullanılarak ikili sınıflandırma gerçekleştirilmiştir. Model çıktısı 0 ile 1 arasında bir olasılık değeri olup, bu değer belirli bir eşik (0.5) üzerinden değerlendirilerek görüntünün “kanamalı” veya “normal” olarak sınıflandırılması sağlanmaktadır.

Modelin eğitimi sırasında Adam optimizasyon algoritması kullanılmış ve kayıp fonksiyonu olarak binary cross-entropy tercih edilmiştir. Ayrıca eğitim sürecinde Early Stopping yöntemi kullanılarak doğrulama başarımında iyileşme durduğunda eğitim otomatik olarak sonlandırılmıştır. Bu yaklaşım, modelin gereksiz yere uzun

süre eğitilmesini engellemiş ve overfitting riskini azaltmıştır.

B. Transfer Learning (ResNet50)

Bu çalışmada kullanılan ikinci model, transfer öğrenme yaklaşımı temel alınarak geliştirilmiş olup, ImageNet veri seti üzerinde önceden eğitilmiş ResNet50 mimarisine dayanmaktadır. ResNet50, derin sinir ağlarında karşılaşılan gradyan kaybolması problemini çözmek amacıyla geliştirilmiş ve artık bağlantılar (residual connections) içeren güçlü bir mimaridir.

Transfer learning yaklaşımı sayesinde, model daha önce büyük veri setleri üzerinde öğrenmiş olduğu genel görsel özellikleri (kenarlar, dokular, şekiller) kullanarak yeni veri seti üzerinde daha hızlı ve etkili bir şekilde öğrenme gerçekleştirmektedir. Bu durum özellikle veri setinin sınırlı olduğu çalışmalarda büyük avantaj sağlamaktadır.

ResNet50 modeli, bu çalışmada sınıflandırma katmanı (top layer) çıkarılarak kullanılmıştır (include_top=False). Modelin sonuna, probleme uygun olacak şekilde yeni tam bağlantılı katmanlar eklenmiştir. Bu katmanlar, global average pooling, dense ve dropout katmanlarından oluşmaktadır.

Modelin eğitimi iki aşamada gerçekleştirilmiştir. İlk aşamada, ResNet50 modelinin tüm katmanları dondurulmuş (frozen) ve yalnızca sonradan eklenen sınıflandırıcı katmanlar eğitilmiştir. Bu sayede modelin önceden öğrendiği özellikler korunmuş ve yalnızca yeni probleme uyum sağlanmıştır.

İkinci aşamada ise fine-tuning işlemi uygulanmıştır. Bu aşamada modelin son katmanları yeniden eğitime açılmış ve düşük bir öğrenme oranı ile modelin ağırlıkları güncellenmiştir. Bu işlem, modelin daha spesifik özellikleri öğrenmesini sağlayarak performansını artırmıştır.

Ayrıca ResNet50 modelinde, orijinal eğitim sürecine uygun olması için özel bir ön işleme yöntemi (preprocess_input) kullanılmıştır. Bu yöntem, görüntülerin piksel değerlerini modelin beklediği formata dönüştürerek daha doğru sonuçlar elde edilmesini sağlamaktadır.

Bu iki aşamalı eğitim yaklaşımı sayesinde, model hem hızlı öğrenmiş hem de yüksek doğruluk oranına ulaşmıştır.

V. EĞİTİM SÜRECİ

Bu çalışmada geliştirilen her iki model de TensorFlow/Keras kütüphanesi kullanılarak eğitilmiştir. Eğitim sürecinde, optimizasyon algoritması olarak adaptif öğrenme oranı sağlayan Adam (Adaptive Moment Estimation) optimizasyon yöntemi tercih edilmiştir. Bu algoritma, parametre güncellemelerini dinamik olarak ayarlayarak modelin daha hızlı ve stabil bir şekilde öğrenmesini sağlamaktadır.

Model eğitiminde kayıp fonksiyonu olarak ikili sınıflandırma problemleri için yaygın olarak kullanılan binary cross-entropy tercih edilmiştir. Bu fonksiyon, modelin tahminleri ile gerçek etiketler arasındaki farkı ölçerek öğrenme sürecini yönlendirmektedir.

Eğitim sürecinde, veri seti belirli bir batch size ile parçalara ayrılarak modele beslenmiştir. Her bir epoch boyunca model, eğitim verisi üzerinde ileri besleme

(forward pass) ve geri yayılım (backpropagation) işlemlerini gerçekleştirerek ağırlıklarını güncellemiştir. Bu süreçte model, hatasını minimize edecek şekilde sürekli olarak kendini geliştirmiştir.

Aşırı öğrenmeyi (overfitting) önlemek ve eğitim sürecini optimize etmek amacıyla Early Stopping yöntemi kullanılmıştır. Bu yöntemde, doğrulama (validation) kaybı belirli bir süre boyunca iyileşme göstermediğinde eğitim otomatik olarak durdurulmuştur. Böylece modelin gereksiz yere uzun süre eğitilmesi engellenmiş ve genelleme performansı artırılmıştır.

Özgün CNN modeli eğitim süreci sonunda yaklaşık %89–91 doğrulama doğruluğu elde etmiştir. Eğitim ve doğrulama metrikleri incelendiğinde, modelin zamanla öğrenme başarısını artırdığı ve stabil bir performans sergilediği gözlemlenmiştir.

Transfer learning tabanlı ResNet50 modeli ise önceden eğitilmiş ağırlıklar sayesinde daha hızlı bir öğrenme süreci geçirmiştir. İlk aşamada yalnızca sınıflandırıcı katmanlar eğitilmiş, ardından fine-tuning aşamasında modelin belirli katmanları yeniden eğitime açılarak daha yüksek performans elde edilmiştir.

Her iki modelin eğitim sürecinde elde edilen doğruluk ve kayıp değerleri grafikler aracılığıyla analiz edilmiş ve modellerin öğrenme davranışları karşılaştırılmıştır. Bu analizler sonucunda, her iki modelin de veri seti üzerinde başarılı bir şekilde öğrenme gerçekleştirdiği belirlenmiştir.

VI. PERFORMANS DEĞERLENDİRMESİ

Geliştirilen modellerin performansı, eğitim sürecinden tamamen bağımsız tutulan test veri seti üzerinde değerlendirilmiştir. Bu yaklaşım sayesinde modellerin daha önce görmediği veriler üzerindeki genelleme yeteneği ölçülmüştür.

Değerlendirme sürecinde, sınıflandırma problemleri için yaygın olarak kullanılan doğruluk (accuracy), kesinlik (precision), duyarlılık (recall) ve F1-score metrikleri kullanılmıştır. Doğruluk metriği, modelin genel olarak doğru tahmin oranını ifade ederken, kesinlik, modelin “kanamalı” olarak tahmin ettiği örneklerin ne kadarının gerçekten kanamalı olduğunu göstermektedir. Duyarlılık (recall) ise gerçek kanamalı vakaların ne kadarının doğru şekilde tespit edildiğini ölçmektedir. F1-score metriği ise precision ve recall değerlerinin dengeli bir ortalamasını sunarak model performansını daha kapsamlı bir şekilde değerlendirmektedir.

Bu metrikler birlikte ele alındığında, modelin yalnızca genel doğruluğu değil, aynı zamanda özellikle kritik olan kanama vakalarını yakalama başarısı da detaylı bir şekilde analiz edilmiştir. Özellikle medikal uygulamalarda, yanlış negatif (kanamalı olduğu halde normal tahmin edilen) sonuçların önlenmesi büyük önem taşımaktadır.

Modellerin hata dağılımını daha detaylı incelemek amacıyla karmaşıklık matrisi (confusion matrix) oluşturulmuştur. Bu matris sayesinde doğru ve yanlış sınıflandırmalar; doğru pozitif (TP), doğru negatif (TN), yanlış pozitif (FP) ve yanlış negatif (FN) olarak

ayrıştırılmıştır. Böylece modelin hangi sınıflarda daha fazla hata yaptığı görsel olarak analiz edilmiştir.

Ayrıca elde edilen sonuçlar görselleştirilerek modellerin performansları karşılaştırılmıştır. Confusion matrix grafiklerinin yanı sıra doğruluk ve kayıp (loss) değerlerinin epoch bazlı değişimi incelenmiş, modellerin öğrenme süreçleri değerlendirilmiştir.

Yapılan analizler sonucunda her iki modelin de test veri seti üzerinde başarılı sonuçlar verdiği, ancak transfer learning tabanlı modelin bazı durumlarda daha kararlı performans sergilediği gözlemlenmiştir. Genel olarak değerlendirildiğinde, geliştirilen sistemin beyin kanaması tespitiinde güvenilir ve etkili bir performans sunduğu belirlenmiştir.

VII. KULLANICI ARAYÜZÜ

Geliştirilen sistem, kullanıcıların modeli kolay ve etkili bir şekilde kullanabilmesi amacıyla Python tabanlı Streamlit kütüphanesi kullanılarak web tabanlı bir arayüz ile desteklenmiştir. Bu arayüz, teknik bilgiye sahip olmayan kullanıcıların dahi sistemi rahatlıkla kullanabilmesine olanak sağlayacak şekilde sade ve kullanıcı dostu olarak tasarlanmıştır.


Arayüz üzerinden kullanıcılar bilgisayarlarından bir beyin BT görüntüsü seçerek sisteme yükleyebilmektedir. Yüklenen görüntü arka planda otomatik olarak ön işleme adımlarından geçirilmekte ve her iki modele (özgün CNN ve ResNet50) ayrı ayrı gönderilmektedir. Modeller tarafından yapılan tahminler kullanıcıya anlık olarak sunulmaktadır.

Sistem, her model için tahmin edilen sınıf bilgisini (kanamalı/normal) ve buna karşılık gelen güven (olasılık) değerini kullanıcıya göstermektedir. Bu sayede kullanıcı yalnızca sonuç değil, aynı zamanda modelin bu sonuca ne kadar güven duyduğunu da görebilmektedir.


Bunun yanı sıra, sistem iki modelin sonuçlarını karşılaştırarak genel bir değerlendirme oluşturmaktadır. Eğer her iki model de aynı sonucu yüksek güven oranı ile veriyorsa, sistem bu durumu daha güçlü bir öneri olarak kullanıcıya sunmaktadır. Ancak modeller arasında bir uyumsuzluk söz konusu olduğunda kullanıcıya daha dikkatli olunması gerektiği yönünde bir uyarı verilmektedir.

Arayüzde ayrıca model çıktıları daha anlaşılır olması amacıyla yorumlanarak kullanıcıya sunulmaktadır. Böylece teknik çıktılar kullanıcı dostu ifadelerle desteklenmekte ve sistemin bir karar destek aracı olarak etkinliği artırılmaktadır.

Genel olarak geliştirilen arayüz, modelin karmaşık hesaplamalarını kullanıcıdan gizleyerek basit, hızlı ve anlaşılır bir kullanım deneyimi sunmaktadır.



Resim 3. Geliştirilen beyin kanaması analiz sistemine ait kullanıcı arayüzü ana ekranı



Resim 4. Kullanıcı tarafından yüklenen BT görüntüsüne ait model tahmin sonuçlarının gösterildiği arayüz ekranı

VIII. BULGULAR

Geliştirilen özgün CNN mimarisi ve önceden eğitilmiş ResNet50 modelinin beyin kanaması tespiti performansına ait deneysel çıktılar sunulmaktadır. Modellerin öğrenme süreçleri; doğruluk (accuracy) ve kayıp (loss) metrikleri üzerinden 25 ve 30 epoch boyunca takip edilmiştir.

A. Özgün CNN Modeli Performansı


Özgün CNN modelinin eğitim süreci resim 6'da sunulmuştur.

- **Öğrenme Eğrisi:** Eğitim doğruluğu 25 epoch sonunda %98 seviyelerine ulaşırken, doğrulama doğruluğu %89-90 bandında kararlı bir seyir izlemiştir.
- **Kayıp Analizi:** Eğitim kaybı istikrarlı bir şekilde azalmış ancak doğrulama kaybının eğitim kaybindan daha yüksek seyretmesi, modelin öğrenme kapasitesinin sınırlarına ulaştığını göstermektedir.

B. ResNet50 (Pre-trained) Model Performansı


Transfer öğrenme yaklaşımıyla eğitilen ResNet50 modeline ait grafikler Resim 7'de yer almaktadır.

- **İstikrarsızlık:** Modelin eğitim sürecinde, özellikle 15. epoch civarında doğruluk değerinde düşüş ve kayıp değerinde sıçrama gözlemlenmiştir.




Resim 5. Özgün CNN ve ResNet50 modellerinin performans karşılaştırması


Modeller kıyaslandığında, özgün CNN mimarisinin doğruluk, kesinlik ve F1-Skoru açısından ResNet50 modelinden daha iyi bir performans sergilemekte. Diğer bir yandan ResNet50 modelinin duyarlılık (recall) değeri (0,918), özgün CNN modelinden (0,897) daha yüksektir. Bu durum, ResNet50'nin kanama olan vakaları tespit etmede (true positive) oldukça başarılı olmakta ancak özgün CNN'in genel sınıflandırma tutarlılığı daha dengeli bir sonuç verdiğini göstermektedir.




Resim 6. Özgün CNN modeli için eğitim ve doğrulama doğruluğu ile kayıp değerlerinin epoch bazlı değişimi



Resim 7. ResNet50 modeli için eğitim ve doğrulama doğruluğu ile kayıp değerlerinin epoch bazlı değişimi



Resim 8. ResNet50 modeli için karmaşıklık matrisi



Resim 9. Özgün CNN modeli için karmaşıklık matrisi

Tablo 1. Özgün CNN Modeli İçin Bulgular

Metrik	Değer	Teknik Yorum
Accuracy	%89,2	Modelin genel sınıflandırma başarısının yüksek olduğunu göstermektedir..
F1-Skoru	%88,8	Kanamalı olarak tahmin edilen görüntülerin büyük kısmının doğru sınıflandırıldığını ifade eder.
Precision	%89,7	Gerçek kanamalı vakaların büyük bölümünün model tarafından başarıyla tespit edildiğini göstermektedir.
Recall	%89,3	Precision ve recall değerlerinin dengeli olduğunu ve modelin genel performansının güçlü olduğunu göstermektedir.

Tablo 2. ResNet50 Modeli İçin Bulgular

Metrik	Değer	Teknik Yorum
Accuracy	%85,9	Modelin genel doğruluk oranı yüksek olmakla birlikte özgün CNN modeline göre biraz daha düşüktür.
F1-Skoru	%82,1	Kanamalı tahminlerde yanlış pozitiflerin özgün CNN modeline göre biraz daha fazla olduğunu göstermektedir.
Precision	%91,8	Gerçek kanamalı vakaları yakalama başarısının oldukça yüksek olduğunu ifade eder.
Recall	%86,7	Modelin özellikle recall açısından güçlü olduğunu, ancak precision değerinin genel dengeyi bir miktar düşürdüğünü göstermektedir.

IX. SONUÇ

Bu çalışmada, beyin bilgisayarlı tomografi (BT) görüntüleri kullanılarak intrakraniyal kanama (Beyin kanaması) tespiti gerçekleştiren derin öğrenme tabanlı bir sistem geliştirilmiştir. Elde edilen sonuçlar her iki modelin de beyin kanaması tespiti görevinde başarılı performans sergilediğini göstermektedir. Özgün CNN modeli doğruluk ve genel performans açısından dengeli bir yapı sunarken, ResNet50 modeli özellikle duyarlılık (recall) açısından daha yüksek başarı elde ederek kanamalı vakaların tespitinde güçlü bir performans göstermiştir. Geliştirilen sistem yalnızca model performansı açısından değil, aynı zamanda kullanıcı dostu arayüzü sayesinde kullanım açısından da önemli avantajlar sunmaktadır. Kullanıcıların görüntü yükleyerek hızlı bir

şekilde tahmin alabilmeleri sistemi bir karar destek aracı olarak kullanılabilir hale getirmektedir.

Sonuç olarak, bu çalışma derin öğrenme tekniklerinin medikal görüntü analizi alanında etkin bir şekilde kullanılabileceğini ortaya koymakta ve beyin kanaması gibi kritik hastalıkların erken teşhisine katkı sağlayabilecek bir sistem sunmaktadır.

KAYNAKÇA

[1] S. P. Shakina and R. Vignesh, “Automating Brain Hemorrhage Detection through Deep Learning Approaches,” in 2025 International Conference on Emerging Technologies in Engineering Applications (ICETEA), IEEE, 2025.

[2] G. Jayaganesh, L. G. Kalpana Devi, A. Mathi, and K. E. Rajakumari, “Brain Hemorrhage Detection Using Deep Learning,” in 2025 8th International Conference, IEEE, 2025.

[3] D. V. Kumar, V. Ramya, and K. V. Nagendra, “A Deep Dive into Machine Learning and Deep Learning Techniques for Brain Hemorrhage Detection,” in 2025 International Conference, IEEE, 2025.

[4] S. Saha and S. Dutta, “DNN-Reg: A Deep Neural Network for Brain Hemorrhage Deformed CT Image Registration,” in 2025 International Conference, IEEE, 2025.

[5] P. S. Priyanka, P. Varalakshmi, and R. Rohith, “Efficient Brain Hemorrhage Segmentation: A Compact 3D U-Net Deep Learning Approach,” in 2025 International Conference on Emerging Technologies in Engineering Applications (ICETEA), IEEE, 2025.

[6] F. Kitamura, “Head CT Hemorrhage Dataset,” Kaggle, 2019. [Online]. Available:

<https://www.kaggle.com/datasets/felipekitamura/head-ct-hemorrhage>. [Accessed: Apr. 17, 2026].